Analyse exploratoire

Taille du dataset

Nombre de transferts enregistrés

```
nrow(transfers)
```

```
## [1] 4700
```

Le dataset répertorie donc 4700 transferts. Il est sensé contenir les 250 transferts les plus élevés pour chaque saison des dix-neuf dernières saisons :

```
length(unique(transfers$Season))
```

```
## [1] 19
```

Or :

```
19 * 250
```

```
## [1] 4750
```

Nous ne disposons donc pas exactement de 250 transferts par saison :

```
freq <- table(transfers$Season)
sort(freq[freq != 250])
```

```
##
## 2003-2004 2002-2003 2017-2018 2010-2011 2018-2019 2014-2015 2005-2006
##       242       244       244       245       245       246       247
## 2000-2001 2004-2005 2007-2008 2012-2013 2015-2016 2006-2007 2009-2010
##       248       248       248       248       248       249       249
## 2011-2012
##       249
```

Il manque des transferts pour 15 saisons sur 19 mais ce n'est jamais plus de 8 transferts sur 250, ce qui ne devrait pas fausser les mesures de l'influence de la saison que l'on pourra faire par la suite.

Nombre de prédicteurs

```
ncol(transfers)
```

```
## [1] 10
```

```r
colnames(transfers)
```

```
##  [1] "Name"         "Position"     "Age"          "Team_from"
##  [5] "League_from"  "Team_to"      "League_to"    "Season"
##  [9] "Market_value" "Transfer_fee"
```

Nettoyage des données

Vérification des classes des prédicteurs

```r
sapply(transfers, class)
```

```
##         Name     Position          Age    Team_from  League_from
##     "factor"     "factor"    "integer"     "factor"     "factor"
##      Team_to    League_to       Season Market_value Transfer_fee
##     "factor"     "factor"     "factor"    "integer"    "integer"
```

On convertit la variable "Name" au type `character`, utilisé en R pour représenter les `string`. On pourrait dire que le nom est un facteur mais la variable prend tellement de valeurs que cela semble plus pertinent d'en faire un type `character`. On ne le fait pas pour les équipes et les ligues, qui prennent moins de valeurs différentes et peuvent a priori avoir une influence sur le prix des joueurs, contrairement à leur nom.

```r
transfers$Name <- as.character(transfers$Name)
class(transfers$Name)
```

```
## [1] "character"
```

On convertit la variable "Season" en facteur ordonné :

```r
# we use the already alphabetical order of seasons
transfers$Season <- as.ordered(transfers$Season)
```

Vérification cohérence des données

Valeurs manquantes ou nulles

```r
summary(transfers)
```

```
##      Name                         Position         Age
##  Length:4700        Centre-Forward    :1218   Min.   : 0.00
##  Class :character   Centre-Back       : 714   1st Qu.:22.00
##  Mode  :character   Central Midfield  : 487   Median :24.00
##                     Attacking Midfield: 426   Mean   :24.34
##                     Defensive Midfield: 411   3rd Qu.:27.00
##                     Right Winger      : 305   Max.   :35.00
##                     (Other)           :1139
```

```
##      Team_from            League_from        Team_to
##  Inter    :  68   Premier League: 608   Inter    :  97
##  Spurs    :  63   Serie A       : 602   Chelsea  :  96
##  Juventus :  59   Ligue 1       : 428   Man City :  94
##  Chelsea  :  57   LaLiga        : 418   Spurs    :  93
##  FC Porto :  56   1.Bundesliga  : 265   Juventus :  87
##  Liverpool:  56   Série A       : 199   Liverpool:  85
##  (Other)  :4341   (Other)       :2180   (Other)  :4148
##           League_to          Season      Market_value
##  Premier League:1256   2001-2002: 250   Min.   :    50000
##  Serie A       : 739   2008-2009: 250   1st Qu.:  3500000
##  LaLiga        : 525   2013-2014: 250   Median :  6000000
##  1.Bundesliga  : 422   2016-2017: 250   Mean   :  8622469
##  Ligue 1       : 397   2006-2007: 249   3rd Qu.: 10000000
##  Premier Liga  : 328   2009-2010: 249   Max.   :120000000
##  (Other)       :1033   (Other)  :3202   NA's   :1260
##   Transfer_fee
##  Min.   :   825000
##  1st Qu.:  4000000
##  Median :  6500000
##  Mean   :  9447586
##  3rd Qu.: 10820000
##  Max.   :222000000
##
```

Seule la colonne “Market_value” contient des valeurs nulles, à raison de 1260 sur 4700 soit 27 %.

```
# extract rows where Market_value is na
null_market_value <- transfers[is.na(transfers$Market_value) == T,]

# make a contingency table by season
cont <- table(null_market_value$Season)
cont
```

```
##
## 2000-2001 2001-2002 2002-2003 2003-2004 2004-2005 2005-2006 2006-2007
##       248       250       244       242       189        28        20
## 2007-2008 2008-2009 2009-2010 2010-2011 2011-2012 2012-2013 2013-2014
##        13         7         2         4         1         2         2
## 2014-2015 2015-2016 2016-2017 2017-2018 2018-2019
##         1         0         1         3         3
```

```
# proportion of the first five seasons
sum(cont[1:5])
```

```
## [1] 1173
```

```
sum(cont[1:5]) / sum(cont)
```

```
## [1] 0.9309524
```

L’essentiel des valeurs manquantes se concentre donc dans les cinq premières saisons. Nous supprimons les lignes correspondantes, qui représentent 26 % des transferts :

```r
# proportion of transfers that we will remove
nrow(transfers[transfers$Season < "2005-2006",]) / nrow(transfers)
```

```
## [1] 0.2621277
```

```r
# extraction using the order on seasons
transfers <- transfers[transfers$Season > "2005-2006",]
```

Par ailleurs, on voit avec la fonction `summary` que le minimum de la colonne "Age" est 0. On retire le transfert correspondant :

```r
table(transfers$Age)
```

```
##
##  16  17  18  19  20  21  22  23  24  25  26  27  28  29  30  31  32  33
##   4  17  60 123 209 231 300 353 384 377 327 292 214 154 106  40  20   7
##  34  35
##   1   2
```

Un seul transfert étant concerné, nous excluons cette ligne :

```r
transfers <- transfers[transfers$Age != 0,]
nrow(transfers)
```

```
## [1] 3221
```

Valeurs incohérentes

On s'intéresse aux ligues :

```r
levels(transfers$League_from)
```

```
##   [1] " Argentina"                    " Australia"
##   [3] " Brazil"                       " Bulgaria"
##   [5] " Canada"                       " Chile"
##   [7] " China"                        " Colombia"
##   [9] " Croatia"                      " Czech Republic"
##  [11] " Denmark"                      " Ecuador"
##  [13] " England"                      " Finland"
##  [15] " France"                       " Ghana"
##  [17] " Iran"                         " Korea, South"
##  [19] " Latvia"                       " Mexico"
##  [21] " Moldova"                      " Paraguay"
##  [23] " Peru"                         " Portugal"
##  [25] " Qatar"                        " Romania"
##  [27] " Russia"                       " Saudi Arabia"
##  [29] " Scotland"                     " Serbia"
##  [31] " Slovakia"                     " South Africa"
##  [33] " Spain"                        " Sweden"
##  [35] " Tunisia"                      " Ukraine"
```

```
##  [37] " United Arab Emirates"          " United States"
##  [39] " Uruguay"                       " Venezuela"
##  [41] "1.Bundesliga"                   "1.Division"
##  [43] "1.HNL"                          "1.Lig"
##  [45] "1.Liga gr. 1"                   "2.Bundesliga"
##  [47] "2ª B - Grupo I"                 "2ª B - Grupo III"
##  [49] "3.Liga"                         "A Grupa - Championship gr."
##  [51] "Allsvenskan"                    "Auf-/Abstiegsrunde NLA/NLB"
##  [53] "Botola Pro"                     "Bundesliga"
##  [55] "Challenge League"               "Championnat National"
##  [57] "Championship"                   "Ekstraklasa"
##  [59] "Eliteserien"                    "Eredivisie"
##  [61] "First Division"                 "HET Liga"
##  [63] "J1 - 2nd Stage"                 "J1 League"
##  [65] "J2 League"                      "Jupiler Pro League"
##  [67] "K League 1"                     "Korean FA Cup"
##  [69] "LaLiga"                         "LaLiga2"
##  [71] "League One"                     "Liga 1"
##  [73] "Liga 1 - Championship group"    "Liga Águila II"
##  [75] "Liga MX Apertura"               "Liga MX Clausura"
##  [77] "Liga NOS"                       "Ligat ha'Al"
##  [79] "Ligue 1"                        "Ligue 2"
##  [81] "Ligue I Pro"                    "MLS"
##  [83] "NB I."                          "OBOS-ligaen"
##  [85] "Premier League"                 "Premier Liga"
##  [87] "Premiership"                    "Primavera B"
##  [89] "Primera B Nacional"             "Primera Div. Apertura"
##  [91] "Primera División"               "Professional League"
##  [93] "Proximus League"                "Regionalliga Nord"
##  [95] "Rel. Ligue 1"                   "Second Division (bis 03/04)"
##  [97] "Segunda División"               "Serie A"
##  [99] "Série A"                        "Serie A Segunda Etapa"
## [101] "Serie B"                        "Série B"
## [103] "Serie C - A"                    "Serie C - B"
## [105] "Stars League"                   "Super League"
## [107] "Süper Lig"                      "Superettan"
## [109] "SuperLiga"                      "Superligaen"
## [111] "Superligaen Championship round" "Torneo Final"
## [113] "Torneo Inicial"                 "U18 Premier League"
## [115] "U19 Eredivisie"                 "UAE Gulf League"
## [117] "Virsliga"                       "Vysheyshaya Liga"
```

Les 40 premières valeurs sont des valeurs de pays. Les autres valeurs sont bien des ligues. On regarde combien de transferts ont une valeur de pays et non de ligue dans une des deux colonnes de ligues :

```
pays_League_from <- levels(transfers$League_from)[1:40]
pays_League_to <- levels(transfers$League_to)[1:24]
pays <- unique(c(pays_League_from, pays_League_to))
nrow(subset(transfers, League_from %in% pays | League_to %in% pays))
```

```
## [1] 82
```

444 transferts sur 4699 sont concernés, soit presque 10 %. Nous décidons néanmoins de nous en débarrasser :

```r
transfers <- subset(transfers, !(League_from %in% pays | League_to %in% pays))
nrow(transfers)
```

```
## [1] 3139
```

Synthèse

Nous avons changé le type de la conomme “Name”, remaqrqué que 27 % des valeurs de la colonne “Market_value étaient manquantes, principalement sur les cinq premières saisons, supprimé l’unique transfert où l’âge du joueur était nul, et supprimé les 10 % de transferts donc la colonne”League_from" ou “League_to” avait pour valeur un pays.

Première étude des données

```r
length(levels(transfers$Team_from))
```

```
## [1] 570
```

```r
length(levels(transfers$Team_to))
```

```
## [1] 325
```

Les 4699 transferts se répartissent en 570 clubs vendeurs et 325 clubs acheteurs. Cette différence pourraiy s’expliquer par le fait que certains clubs vendent cher des joueurs dont ils ont fait augmenter la valeur après les avoir acheté à faible prix. Il y a une concentration des mêmes clubs acheteurs dans les transferts les plus élevés.